

SVEUČILIŠTE JURJA DOBRILE U PULI
FAKULTET INFORMATIKE

Neven Nižić

**”Optimizacija raspodjele projektnih aktivnosti primjenom genetskih
algoritama i Monte Carlo simulacije”**

DIPLOMSKI RAD

Pula, rujan, 2025. godine

SVEUČILIŠTE JURJA DOBRILE U PULI
FAKULTET INFORMATIKE

Neven Nižić

**”Optimizacija raspodjele projektnih aktivnosti primjenom genetskih
algoritama i Monte Carlo simulacije”**

DIPLOMSKI RAD

**JMBAG: 0303118917, izvanredni student
Studijski smjer: Informatika**

**Kolegij: Modeliranje i simulacije
Znanstveno područje : Društvene znanosti
Znanstveno polje : Informacijske i komunikacijske znanosti
Znanstvena grana : Informacijski sustavi i informatologija**

Mentor: doc.dr.sc. Darko Etinger

Pula, rujan, 2025. godine

Sažetak

Upravljanje projektima često uključuje složene odluke vezane uz raspodjelu aktivnosti i resursa, osobito u uvjetima nesigurnosti i vremenskih ograničenja. Tradicionalne metode kao što su PERT i CPM često ne uspijevaju obuhvatiti stohastičku prirodu stvarnih projekata. U ovom radu predlaže se model koji kombinira genetske algoritme i Monte Carlo simulaciju s ciljem postizanja robusne optimizacije raspodjele projektnih aktivnosti. Genetski algoritam koristi se za pretraživanje prostora mogućih rješenja, dok Monte Carlo simulacija omogućava procjenu utjecaja varijabilnih trajanja aktivnosti na ukupno trajanje projekta. Eksperimentalna evaluacija modela provodi se na simuliranim projektnim podacima, a rezultati pokazuju poboljšanu robusnost i učinkovitost u odnosu na determinističke pristupe.

Ključne riječi : projektno upravljanje, genetski algoritam, Monte Carlo simulacija, optimizacija rasporeda, raspodjela aktivnosti

Abstract

Project management often involves complex decisions related to the allocation of activities and resources, especially under uncertainty and time constraints. Traditional methods such as PERT and CPM frequently fail to capture the stochastic nature of real-world projects. This thesis proposes a model that combines genetic algorithms and Monte Carlo simulation to achieve robust optimization of project activity allocation. The genetic algorithm is used to explore the space of possible solutions, while Monte Carlo simulation estimates the impact of variable activity durations on the overall project timeline. The model is experimentally evaluated using simulated project data, and results indicate improved robustness and efficiency compared to deterministic approaches.

Keywords : project management, genetic algorithm, Monte Carlo simulation, schedule optimization, activity allocation

Sadržaj

1	Uvod	1
1.1	Uvodni dio	1
1.2	Motivacija	1
1.3	Rizici i nesigurnosti u projektnom upravljanju	1
1.4	Ciljevi i istraživačka pitanja	2
2	Teorijska podloga	3
2.1	Knapsack problem	3
2.2	Genetski algoritmi	3
2.3	Monte Carlo simulacija	4
2.4	PERT metoda i trokutasta distribucija	5
2.5	Zaključak	5
3	Model problema	7
3.1	Ograničenja	7
3.2	Cilj optimizacije	7
3.3	Grafički prikaz modela	7
3.4	Zaključak poglavlja	8
4	Implementacija	9
4.1	Korištene biblioteke	9
4.2	Struktura implementacije	9
4.2.1	Monte Carlo modul	11
4.2.2	GA modul	11
4.2.3	Vizualizacija rezultata	11
5	Eksperimenti	13
5.1	Testni podaci	13
5.2	Scenariji testiranja	13
5.3	Metodologija	13
5.4	Plan prezentacije rezultata	14
6	Zaključak	15
	Literatura	16
	Popis slika	18
	Popis tablica	19

1 Uvod

1.1 Uvodni dio

Jedan od modela koji dobro opisuje izazove alokacije resursa je *problem ruksaka* (*Knapsack Problem*), gdje se ograničeni resursi moraju raspodijeliti na način koji maksimizira ukupnu korist [1]. U kontekstu projektnih aktivnosti, to znači odabrati skup zadataka koji će donijeti najveći povrat ulaganja (ROI) uz poštivanje vremenskih i resursnih ograničenja. Tradicionalne metode poput PERT-a (*Program Evaluation and Review Technique*) i CPM-a (*Critical Path Method*) [2, 3] pružaju okvir za planiranje i praćenje projekata, no često zanemaruju složene kombinacije zadataka i inherentnu neizvjesnost u procjenama trajanja i troškova.

Pregled literature pokazuje da se genski algoritmi (GA) uspješno primjenjuju na NP-teške optimizacijske probleme [4, 5], dok Monte Carlo simulacije (MC) omogućuju modeliranje i kvantifikaciju neizvjesnosti [6, 7]. Međutim, u literaturi postoji ograničen broj radova koji integriraju ove dvije metode u jedinstven hibridni pristup optimizaciji projektnih aktivnosti [8, 9]. Praznina se očituje u nedostatku sustavne analize kako kombinacija GA i MC može povećati robusnost rješenja u uvjetima visoke neizvjesnosti i složenih resursnih ograničenja.

1.2 Motivacija

Motivacija za ovaj rad proizlazi iz činjenice da se u stvarnim projektnim uvjetima planovi rijetko odvijaju točno onako kako su prvotno predviđeni [3]. Promjene u dostupnosti resursa, nepredviđeni rizici, promjene zahtjeva te pogrešne procjene trajanja zadataka česti su razlozi odstupanja od plana. Klasične metode planiranja projekata, iako korisne, često ne uzimaju u obzir dinamičke promjene i stohastičku prirodu projektnih parametara [10].

Upravo zbog toga potrebne su metode koje ne samo da optimiziraju raspodjelu resursa, već i uvažavaju nesigurnosti te omogućuju procjenu rizika povezanih s odabranim rješenjima. Genski algoritmi pružaju snažan alat za globalnu optimizaciju složenih problema pretrage [5], dok Monte Carlo simulacije omogućuju procjenu varijabilnosti i rizika rješenja [7]. Kombiniranjem ovih metoda moguće je razviti pristup koji generira kvalitetna rješenja, a pritom osigurava njihovu robusnost u uvjetima nesigurnosti [9].

1.3 Rizici i nesigurnosti u projektnom upravljanju

Rizici u projektnom upravljanju obuhvaćaju sve događaje ili uvjete koji, ako se pojave, mogu negativno utjecati na ciljeve projekta [11]. Oni mogu biti tehničke, organizacijske, financijske ili tržišne prirode, a često su međusobno povezani [10]. Nesigurnosti proizlaze iz nepotpunih informacija, promjenjivih uvjeta i nemogućnosti preciznog predviđanja budućih događaja [12]. Upravljanje rizicima uključuje njihovu identifikaciju, procjenu i razvoj strategija odgovora [11].

Monte Carlo simulacije predstavljaju jedan od najučinkovitijih pristupa kvantitativnoj procjeni rizika [13]. Kroz generiranje velikog broja scenarija temeljenih

na slučajnim varijacijama ulaznih parametara, moguće je procijeniti distribuciju mogućih ishoda i vjerojatnosti ostvarenja ciljeva projekta [7].

1.4 Ciljevi i istraživačka pitanja

Ovaj diplomski rad ima za cilj razviti i evaluirati hibridni GA-MC model za optimizaciju raspodjele projektnih aktivnosti. Doprinos rada je trojak:

- **Teorijski doprinos:** povezivanje optimizacijskih tehnika s metodama procjene neizvjesnosti u kontekstu projektnih aktivnosti.
- **Metodološki doprinos:** razvoj integriranog modela koji povezuje evolucijsku optimizaciju i statističku simulaciju.
- **Praktični doprinos:** demonstracija primjenjivosti pristupa na sintetičkim projektnim podacima i analiza performansi modela.

Istraživačka pitanja na koja ovaj rad želi odgovoriti su:

1. Može li hibridni GA-MC pristup postići bolje rezultate optimizacije u odnosu na samostalnu primjenu GA ili MC?
2. U kojoj mjeri Monte Carlo simulacija može poboljšati robusnost rješenja dobivenih genskim algoritmom?
3. Kakav je utjecaj kombiniranog pristupa na stabilnost i pouzdanost optimizacije u uvjetima neizvjesnosti?

Ciljevi istraživanja su:

- Dizajnirati i implementirati integrirani GA-MC model.
- Evaluirati performanse modela na različitim scenarijima.
- Usporediti rezultate hibridnog pristupa s rezultatima pojedinačnih metoda.

Sinergija između genskih algoritama i Monte Carlo simulacija proizlazi iz njihove komplementarne prirode: GA učinkovito pretražuje veliki prostor mogućih rješenja i pronalazi visokokvalitetne kandidate [5], dok MC kvantificira rizik i procjenjuje varijabilnost tih rješenja kroz stohastičko modeliranje [7]. Kombinacija ovih metoda rezultira robusnim pristupom koji ne samo da optimizira projektne aktivnosti, već i uzima u obzir realne nesigurnosti u planiranju.

Struktura rada organizirana je na sljedeći način:

- **Poglavlje 2** daje pregled relevantne literature i teorijskih osnova problema.
- **Poglavlje 3** opisuje korištenu metodologiju, uključujući principe rada GA i MC.
- **Poglavlje 4** prikazuje implementaciju hibridnog modela.
- **Poglavlje 5** opisuje plan i rezultate eksperimentalnog vrednovanja modela.
- **Poglavlje 6** sadrži zaključak i preporuke za budući rad.

2 Teorijska podloga

Ovo poglavlje pruža pregled temeljnih teorijskih koncepata ključnih za razumijevanje predloženog modela optimizacije projektnih aktivnosti. Detaljno će se objasniti Problem ruksaka kao osnova za formulaciju problema raspodjele resursa, Genetski algoritmi kao optimizacijska metaheuristika, te Monte Carlo simulacija i PERT metoda kao alati za modeliranje i analizu nesigurnosti u projektnom upravljanju.

2.1 Knapsack problem

Problem ruksaka (engl. *Knapsack Problem*) jedan je od najpoznatijih i najčešće proučavanih problema kombinatorne optimizacije, svrstan u klasu NP-teških problema [5]. U osnovnoj verziji, cilj je odabrati podskup objekata s pridruženom težinom i vrijednošću, s ciljem maksimiziranja ukupne vrijednosti odabranih objekata, pri čemu njihova ukupna težina ne smije prelaziti zadani kapacitet ruksaka.

Formalno, za skup od n objekata, gdje svaki objekt i ima težinu w_i i vrijednost v_i , te uz zadani kapacitet ruksaka W , cilj je maksimizirati funkciju:

$$\max \sum_{i=1}^n v_i x_i \quad \text{uz ograničenje} \quad \sum_{i=1}^n w_i x_i \leq W, \quad x_i \in \{0, 1\}$$

gdje je $x_i = 1$ ako je objekt i odabran, a $x_i = 0$ ako nije.

U kontekstu upravljanja projektima, ovaj se problem često pojavljuje u složenijim varijantama, poput višedimenzionalnog problema ruksaka (Multi-Dimensional Knapsack Problem – MDKP). U MDKP-u, osim jedne težine, svaki objekt (projektna aktivnost) ima više dimenzija "težine" koje predstavljaju različite vrste resursa (npr. vrijeme, budžet, broj radnika, specifična oprema). Kapacitet ruksaka tada predstavlja ograničenja za svaku od tih dimenzija. Projektne aktivnosti se mogu interpretirati kao objekti s određenim trajanjem, troškom i vrijednošću (npr. strateška važnost, povrat investicije – ROI), dok resursi projekta predstavljaju kapacitet ruksaka. MDKP se stoga koristi za optimalnu raspodjelu ograničenih, višestrukih resursa među konkurentskim projektnim aktivnostima, s ciljem maksimiziranja ukupne vrijednosti ili minimiziranja ukupnog trajanja projekta.

2.2 Genetski algoritmi

Genetski algoritmi (GA) su moćne metaheurističke optimizacijske metode inspirirane procesima prirodne selekcije i evolucije [5, 14]. Pripadaju široj klasi evolucijskih algoritama i iznimno su učinkoviti u rješavanju složenih optimizacijskih problema s velikim i nepreglednim prostorom rješenja, posebno onih NP-teških, za koje klasične metode nisu praktične [15, 16].

Osnovni princip GA leži u simulaciji evolucije populacije potencijalnih rješenja. Svako rješenje problema kodira se kao *kromosom* (obično binarni niz, ali može biti i cijeli broj, realni broj ili permutacija), a populacija kromosoma se iterativno poboljšava kroz generacije primjenom genetskih operatora. Tipični koraci genetskog algoritma uključuju:

1. **Inicijalizacija populacije:** Generira se početni skup nasumičnih ili heuristički generiranih kromosoma.
2. **Evaluacija funkcije cilja (fitness):** Svakom kromosomu dodjeljuje se vrijednost *fitnessa* koja odražava kvalitetu rješenja. U kontekstu ovog rada, fitness funkcija uključuje rezultate Monte Carlo simulacije kako bi se procijenila robusnost i vjerojatnost uspjeha projekta [15].
3. **Selekcija roditelja:** Kromosomi s višim fitnessom imaju veću vjerojatnost da budu odabrani kao roditelji (npr. turnirska selekcija, rulet, rang-selekcija).
4. **Križanje (crossover):** Dva odabrana roditelja kombiniraju se kako bi se stvorili novi potomci, prenoseći genetski materijal. Ovo omogućuje istraživanje novih dijelova prostora rješenja.
5. **Mutacija:** Slučajne, male promjene unose se u kromosome potomaka kako bi se održala genetska raznolikost populacije i izbjegla prerana konvergencija.
6. **Zamjena populacije:** Nova generacija potomaka zamjenjuje dio ili cijelu staru populaciju, i proces se ponavlja dok se ne ispuni kriterij zaustavljanja.

Kodiranje rješenja u problemima raspodjele projektnih aktivnosti često uključuje binarno kodiranje (gdje svaki bit predstavlja odabir ili ne-odabir aktivnosti) ili cjelobrojno kodiranje (gdje brojevi predstavljaju redoslijed aktivnosti ili dodjelu resursa). GA su posebno prikladni za probleme gdje nije poznata funkcija gradijenta, što ih čini fleksibilnima za širok spektar primjena.

2.3 Monte Carlo simulacija

Monte Carlo simulacija (MCS) je računska metoda koja koristi nasumično uzorkovanje za procjenu ponašanja složenog sustava ili procesa, posebno kada je analitičko rješenje teško ili nemoguće. Njena je primarna prednost sposobnost modeliranja nesigurnosti i rizika u sustavima s probabilističkim ulaznim varijablama [13]. U kontekstu projektnog upravljanja, MCS je vrijedan alat za procjenu vjerojatnih ishoda projekta, poput trajanja i troškova, uzimajući u obzir varijabilnost aktivnosti [17, 18].

Ključni elementi MCS uključuju:

- **Definiranje slučajnih varijabli:** Identificiraju se ulazne varijable čija je vrijednost neizvjesna (npr. trajanje aktivnosti, troškovi resursa).
- **Odabir distribucije vjerojatnosti:** Za svaku varijablu odabire se distribucija koja najbolje opisuje njeno ponašanje (npr. uniformna, normalna, log-normalna, trokutasta).
- **Generiranje nasumičnih uzoraka:** Velik broj uzoraka generira se iz odabranih distribucija.

- **Provođenje simulacije:** Za svaki skup uzoraka provodi se izračun modela.
- **Analiza rezultata:** Nakon velikog broja iteracija (npr. $n > 10^3$ do 10^5), prikupljeni podaci se analiziraju statistički kako bi se procijenile distribucije izlaznih varijabli.

2.4 PERT metoda i trokutasta distribucija

PERT (*Program Evaluation and Review Technique*) je metoda upravljanja projektima razvijena za planiranje i kontrolu projekata s neizvjesnim trajanjem aktivnosti. Ključna značajka PERT-a je korištenje tri vremenske procjene [3]:

- T_o – optimistična procjena trajanja,
- T_m – najvjerojatnija procjena trajanja,
- T_p – pesimistična procjena trajanja.

Očekivano trajanje aktivnosti računa se pomoću:

$$T_E = \frac{T_o + 4T_m + T_p}{6}$$

Tradicionalno, PERT koristi beta distribuciju, no u praksi se često primjenjuje trokutasta distribucija, posebno u kombinaciji s Monte Carlo simulacijom. Parametri trokutaste distribucije definiraju se pomoću T_o , T_m i T_p , a očekivana vrijednost izračunava se formulom:

$$E[X] = \frac{T_o + T_m + T_p}{3}$$

Trokutasta distribucija pogodna je za slučajeve kada su dostupne samo procjene temeljene na stručnom iskustvu, a ne i detaljni povijesni podaci. Njena jednostavnost i intuitivnost čine je čestom u praksi projektnog upravljanja, posebno u ranoj fazi planiranja.

2.5 Zaključak

Primjena genetskih algoritama u kombinaciji s Monte Carlo simulacijom pokazala se kao učinkovita metoda za optimizaciju raspodjele projektnih aktivnosti u uvjetima neizvjesnosti. Genetski algoritmi omogućuju pronalazak rješenja visoke kvalitete unutar složenog prostora mogućnosti, dok Monte Carlo simulacija pruža statističku procjenu rizika i vjerojatnosti ostvarenja projektnog plana. Ovakav pristup omogućuje menadžerima projekata donošenje informiranih odluka i bolje upravljanje rizicima, čime se povećava vjerojatnost uspjeha projekta.

Međutim, u kontekstu Monte Carlo simulacije, tri točke procjene (T_o, T_m, T_p) često se koriste za definiranje parametara *trokutaste distribucije*. Trokutasta distribucija popularna je u projektnom upravljanju zbog svoje jednostavnosti implementacije i intuitivnosti. Omogućuje modeliranje varijabilnosti trajanja aktivnosti kada su dostupne samo tri procjene, a opsežni povijesni podaci možda

nedostaju [19]. Očekivana vrijednost računa se formulom:

$$E(T) = \frac{T_o + T_m + T_p}{3}$$

Vrijednosti generirane iz trokutaste distribucije u svakoj simulaciji odabiru se unutar intervala $[T_o, T_p]$, pri čemu je najveća vjerojatnost pojavljivanja oko vrijednosti T_m . Korištenje trokutaste distribucije u Monte Carlo simulaciji omogućuje realističniji prikaz varijabilnosti trajanja aktivnosti u projektnom planiranju, što rezultira robusnijim procjenama ukupnog trajanja projekta i većom preciznošću u procjeni vjerojatnosti uspjeha.

3 Model problema

Projekt optimizacije raspodjele projektnih aktivnosti može se formalno predstaviti kao skup od n zadataka, pri čemu svaki zadatak i ima definirane sljedeće karakteristike:

- **procijenjeno trajanje** d_i ,
- **trošak** c_i ,
- **vrijednost** odnosno povrat ulaganja (ROI) v_i ,
- **distribucija nesigurnosti** koja opisuje varijabilnost trajanja i/ili troška.

Ovakav formalizam omogućuje primjenu metoda kombinatorne optimizacije [20] i stohastičkih simulacija [19] za donošenje optimalnih odluka u uvjetima ograničenih resursa.

3.1 Ograničenja

Projekt je podložan realnim ograničenjima resursa, koja se u modelu izražavaju na sljedeći način:

$$\sum_{i=1}^n d_i \leq T_{\max} \quad (\text{ukupno vrijeme}) \quad (1)$$

$$\sum_{i=1}^n c_i \leq B_{\max} \quad (\text{budžet}) \quad (2)$$

$$\sum_{i=1}^n r_i \leq R_{\max} \quad (\text{maksimalan broj radnika}) \quad (3)$$

gdje T_{\max} označava raspoloživo ukupno vrijeme, B_{\max} raspoloživi budžet, a R_{\max} maksimalan broj raspoloživih radnika.

3.2 Cilj optimizacije

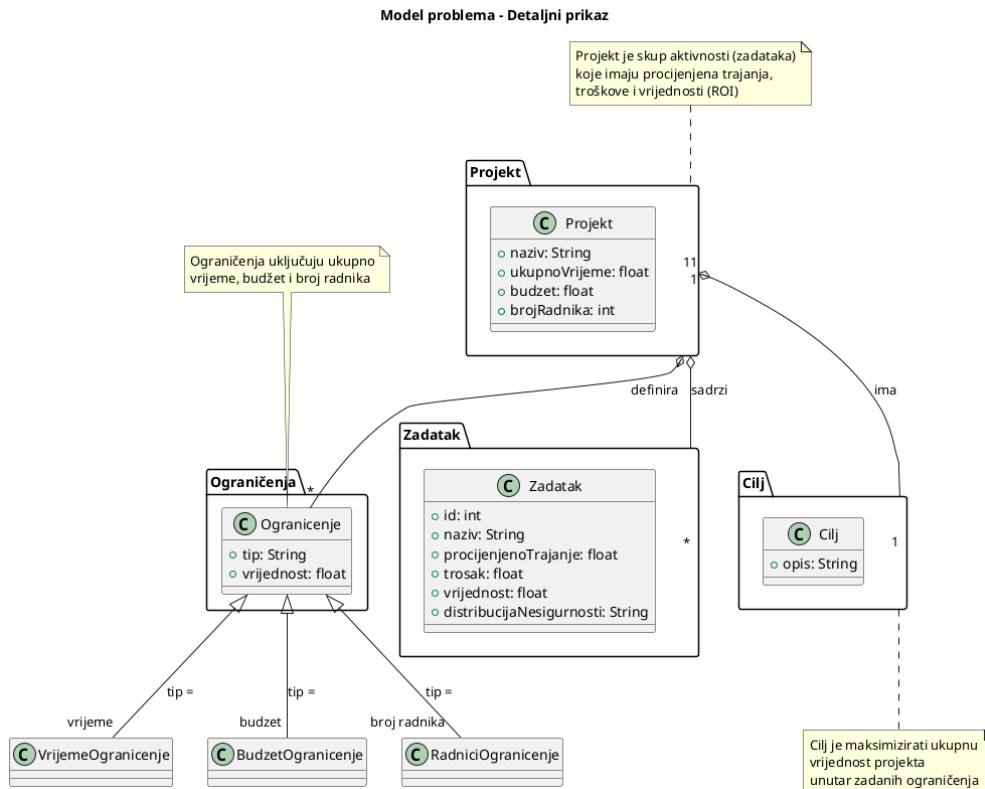
Cilj optimizacije je **maksimizirati ukupnu vrijednost projekta** ostajući unutar svih definiranih ograničenja:

$$\max \sum_{i=1}^n v_i \cdot x_i \quad (4)$$

pri čemu $x_i \in \{0, 1\}$ označava binarnu varijablu koja označava odabir zadatka i za izvršenje.

3.3 Grafički prikaz modela

Na slici 1 prikazan je konceptualni model problema optimizacije raspodjele projektnih aktivnosti, uključujući ulazne podatke, ograničenja i ciljnu funkciju.



Slika 1: Model problema optimizacije raspodjele projektnih aktivnosti

3.4 Zaključak poglavlja

Ovaj model problema omogućuje matematičku i vizualnu formalizaciju optimizacijskog zadatka. Jasna definicija ulaza, ograničenja i cilja ključna je za primjenu optimizacijskih metoda poput genetskih algoritama [5] u kombinaciji s Monte Carlo simulacijama kako bi se dobila rješenja visoke kvalitete u uvjetima nesigurnosti.

4 Implementacija

Implementacija razvijenog modela optimizacije provedena je u programskom jeziku Python, zbog njegove fleksibilnosti, bogatog ekosustava biblioteka te široke primjene u znanstvenom računarstvu i optimizacijskim metodama. Python omogućuje brz razvoj prototipa, jednostavnu integraciju različitih modula te učinkovitu vizualizaciju rezultata.

4.1 Korištene biblioteke

Za potrebe izrade sustava korištene su sljedeće biblioteke:

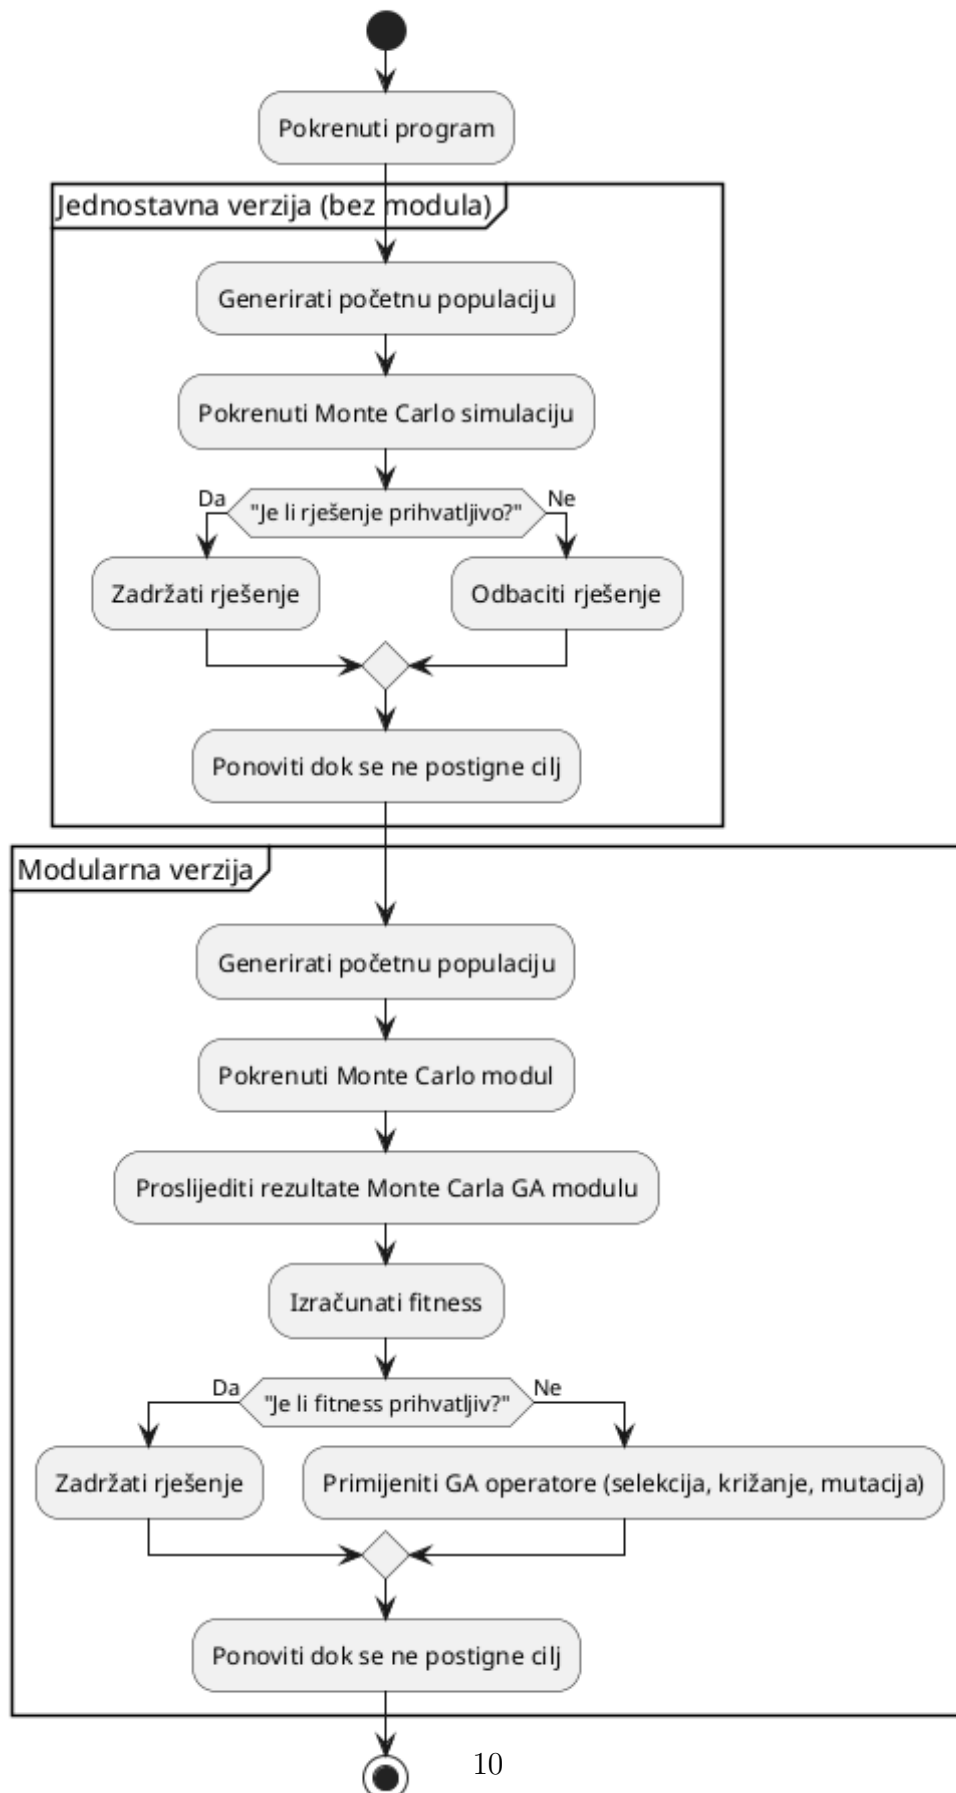
- **NumPy** – osnovna biblioteka za rad s višedimenzionalnim poljima i vektorima, pruža optimizirane matematičke funkcije te omogućuje učinkovito generiranje slučajnih brojeva potrebnih za Monte Carlo simulacije.
- **random** – ugrađeni Python modul za generiranje slučajnih vrijednosti, korišten u inicijalnim fazama simulacije i generiranja početnih populacija u genetskom algoritmu.
- **matplotlib** – biblioteka za vizualizaciju podataka, korištena za grafički prikaz distribucija trajanja zadataka, konvergencije genetskog algoritma i usporedbu dobivenih rješenja.
- **DEAP** (Distributed Evolutionary Algorithms in Python) – opcionalna biblioteka za implementaciju genetskih algoritama i drugih evolucijskih metoda. Omogućuje jednostavnu definiciju operatora selekcije, križanja i mutacije, kao i prilagodbu parametara evolucijskog procesa.

4.2 Struktura implementacije

Implementacija je podijeljena u tri glavna modula:

1. **Monte Carlo modul** – odgovoran za generiranje distribucija trajanja zadataka i procjenu nesigurnosti.
2. **Genetski algoritam (GA) modul** – provodi optimizaciju raspodjele projektnih aktivnosti koristeći rezultate Monte Carlo simulacije.
3. **Modul za vizualizaciju** – omogućuje analizu rezultata kroz grafičke prikaze i usporedbe.

Usporedba jednostavne i modularne verzije programa



Slika 2: Dijagram toka procesa optimizacije korištenjem Monte Carlo simulacije i genetskog algoritma

4.2.1 Monte Carlo modul

Monte Carlo simulacija implementirana je korištenjem biblioteka NumPy i random. Za svaki zadatak definirana je procijenjena vrijednost trajanja (optimistična, pesimistična i najvjerojatnija procjena). Generiranjem velikog broja simulacija (npr. 10^4 iteracija), dobivena je empirijska distribucija trajanja svakog zadatka.

Pseudokod implementacije Monte Carlo modula:

```
for svaki zadatak u projektu:
    generiraj nasumične vrijednosti trajanja prema odabranoj distribuciji
    spremi rezultate u niz
procijeni prosjek, medijan i standardnu devijaciju trajanja
```

Rezultat Monte Carlo simulacije je skup distribucija koji se koristi u evaluacijskoj funkciji genetskog algoritma.

4.2.2 GA modul

Genetski algoritam implementiran je pomoću biblioteke DEAP, a u slučaju jednostavnije implementacije korišteni su osnovni Python moduli random i NumPy. Ključne komponente GA modula su:

- **Inicijalizacija populacije** – generira se početna populacija rješenja koja predstavlja različite načine raspodjele projektnih aktivnosti.
- **Funkcija prilagodbe (fitness)** – izračunava kvalitetu rješenja na temelju trajanja, troškova i vrijednosti dobivenih iz Monte Carlo simulacije.
- **Selekcija** – odabire najbolja rješenja prema definiranim kriterijima (npr. turnirska selekcija).
- **Križanje (crossover)** – kombinira dijelove rješenja dvaju roditelja kako bi se stvorila nova, potencijalno bolja rješenja.
- **Mutacija** – nasumično mijenja dio rješenja radi očuvanja raznolikosti populacije.
- **Zaustavni uvjet** – algoritam se zaustavlja nakon određenog broja generacija ili kada se konvergencija dostigne.

4.2.3 Vizualizacija rezultata

Za analizu rezultata korištena je biblioteka matplotlib, a rezultati se prikazuju u tri glavne forme:

1. **Distribucije trajanja zadataka** – histogrami i krivulje gustoće dobivene iz Monte Carlo simulacija.
2. **Konvergencija genetskog algoritma** – graf promjene najbolje fitness vrijednosti kroz generacije.

3. **Usporedba rješenja** – prikaz najboljeg pronađenog rješenja naspram prosječnih i početnih rješenja.

Ova struktura implementacije omogućuje fleksibilnu nadogradnju sustava, integraciju dodatnih optimizacijskih metoda i prilagodbu različitim vrstama projekata.

5 Eksperimenti

Cilj ovog poglavlja je provesti eksperimentalnu evaluaciju razvijenog modela optimizacije raspodjele projektnih aktivnosti koji kombinira genetske algoritme (GA) i Monte Carlo simulaciju (MC). U ovoj fazi rada eksperimenti će biti okvirno opisani, dok će se stvarni rezultati i detaljne analize dodati nakon provedbe testiranja.

5.1 Testni podaci

Za potrebe eksperimenta koristit će se sintetički skupovi podataka koji će uključivati:

- različite vrijednosti projektnih aktivnosti,
- različite troškove resursa,
- varijabilna trajanja aktivnosti (optimistično, realno, pesimistično).

Takav pristup omogućava kontrolu nad parametrima te usporedivost rezultata između različitih scenarija.

5.2 Scenariji testiranja

Eksperimenti će biti podijeljeni u tri osnovna scenarija:

1. **Samo GA** — Genetski algoritam optimizira raspodjelu bez uključivanja Monte Carlo simulacije (baseline pristup).
2. **Samo MC** — Monte Carlo simulacija koristi se za procjenu trajanja i uspješnosti bez GA optimizacije.
3. **Kombinacija GA + MC** — Predloženi hibridni pristup gdje se GA koristi za optimizaciju, a MC za evaluaciju potencijalnih rješenja (finalni model).

5.3 Metodologija

Za svaki scenarij provodit će se više ponavljanja kako bi se smanjio utjecaj slučajnih varijacija. Planirane metrike koje će se prikupljati:

- **Broj uspješnih projekata** — koliko projekata je završilo unutar planiranog roka i budžeta.
- **Ukupna ROI vrijednost** — ukupni povrat investicije iz optimizirane raspodjele.
- **Stabilnost rješenja** — varijacija rezultata kroz ponavljanja eksperimenta.

5.4 Plan prezentacije rezultata

Nakon provedbe eksperimenata, rezultati će biti prikazani:

- tablicama (kvantitativni rezultati i usporedbe),
- grafovima (vizualizacija trendova i distribucija),
- opisnim analizama (interpretacija dobivenih rezultata).

Sljedeći grafikon prikazat će usporedbu prosječne uspješnosti između triju scenarija:



Slika 3: Primjer usporedbe prosječne uspješnosti za tri scenarija (primjer, podaci privremeni).

6 Zaključak

U ovom diplomskom radu predstavili smo kompleksan pristup optimizaciji raspodjele projektnih aktivnosti koristeći kombinaciju genetskih algoritama i Monte Carlo simulacije. Cilj je bio razviti model koji uzima u obzir nesigurnost u trajanju, troškovima i vrijednosti zadataka, te u okviru zadanih ograničenja vremena, budžeta i raspoloživih resursa maksimizira ukupnu vrijednost projekta.

Kroz detaljnu analizu problematike i pregled postojeće literature, identificirali smo ključne izazove u upravljanju projektima, posebice u segmentu neizvjesnosti i složenosti optimizacije. Implementacijom metaheurističkih metoda, u ovom slučaju genetskih algoritama [5, 14], omogućili smo efikasno pretraživanje velikog prostora rješenja, dok je Monte Carlo simulacija služila za kvantitativno modeliranje rizika i nesigurnosti [17, 18], dajući time realističniju procjenu performansi optimizacijskog rješenja.

Praktična implementacija rezultirala je modelom koji omogućuje donošenje informiranih odluka u planiranju i upravljanju projektima, pružajući projektnim menadžerima alate za bolje usklađivanje ciljeva i ograničenja. Pokazalo se da je kombinacija ovih metoda učinkovita u pronalasku balansiranih rješenja koja maksimiziraju povrat ulaganja, uz minimizaciju rizika od prekoračenja budžeta ili rokova.

Iako su postignuti rezultati zadovoljavajući, postoje brojna područja za buduća istraživanja i unaprjeđenja, među kojima izdvajamo:

- Proširenje modela na dinamičke uvjete projekata koji se mijenjaju tijekom vremena, uključujući nepredvidive vanjske utjecaje.
- Integracija dodatnih metaheurističkih i hibridnih algoritama, poput algoritama rojčaste inteligencije ili simuliranog kaljenja, radi poboljšanja kvalitete rješenja [15].
- Primjena tehnika strojnog učenja za preciznije predviđanje distribucija nesigurnosti i automatsku adaptaciju parametara optimizacije.
- Razvoj softverskih alata s intuitivnim korisničkim sučeljem za praktičnu primjenu predloženih metoda u realnim projektnim okruženjima.

Zaključno, ovaj rad potvrđuje važnost primjene naprednih algoritamskih rješenja u upravljanju projektima, posebno u uvjetima nesigurnosti, te doprinosi boljem razumijevanju i praktičnoj primjeni optimizacijskih i simulacijskih metoda u području projektne ekonomike i menadžmenta. Kao što ističe Kerzner [3], učinkovito upravljanje projektima u suvremenom okruženju zahtijeva kombinaciju tradicionalnih i naprednih pristupa, a naš model pruža značajan doprinos u tom smjeru.

Literatura

- [1] Hans Kellerer, Ulrich Pferschy, and David Pisinger. *Knapsack Problems*. Springer, 2004.
- [2] D. G. Malcolm, J. H. Roseboom, C. E. Clark, and W. Fazar. Application of a technique for research and development program evaluation. *Operations Research*, 7(5):646–669, 1959.
- [3] Harold Kerzner. *Project Management: A Systems Approach to Planning, Scheduling, and Controlling*. Wiley, 12th edition, 2017.
- [4] John H. Holland. *Adaptation in Natural and Artificial Systems*. University of Michigan Press, Ann Arbor, MI, 1st edition, 1975.
- [5] David E. Goldberg. *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley, 1989.
- [6] Nicholas Metropolis, Arianna W. Rosenbluth, Marshall N. Rosenbluth, Augusta H. Teller, and Edward Teller. Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6):1087–1092, 1949.
- [7] Reuven Y. Rubinstein and Dirk P. Kroese. *Simulation and the Monte Carlo Method*. Wiley, 3rd edition, 2016.
- [8] Kalyanmoy Deb, Amrit Pratap, Sameer Agarwal, and T. Meyarivan. A fast and elitist multiobjective genetic algorithm: Nsga-ii. *IEEE Transactions on Evolutionary Computation*, 6(2):182–197, 2002.
- [9] Wei Zhang and Ming Li. An efficient algorithm for project scheduling under uncertainty. *International Journal of Project Management*, 29(5):567–574, 2011.
- [10] Project Management Institute. *A Guide to the Project Management Body of Knowledge (PMBOK Guide)*. PMI, 7th edition, 2021.
- [11] David Hillson. *Managing Risk in Projects*. Routledge, 2009.
- [12] Pete Smith. *Project Uncertainty: Managing Risk in New Ventures*. Routledge, 2014.
- [13] David Vose. *Risk Analysis: A Quantitative Guide*. John Wiley & Sons, 2008.
- [14] Melanie Mitchell. *An Introduction to Genetic Algorithms*. MIT Press, 1998.
- [15] Amir H. Gandomi, Xin-She Yang, Siamak Talatahari, and Amir H. Alavi. Metaheuristic algorithms in modeling and optimization. *Applied Soft Computing*, 13(1):1–11, 2013.

- [16] A. Kaveh and S. Talatahari. A comparative study of metaheuristic optimization algorithms for optimal design of truss structures. *Computers & Structures*, 102:66–75, 2012.
- [17] Roger Miller and Donald Lessard. Project risk management using monte carlo simulation. *Project Management Journal*, 40(3):23–33, 2009.
- [18] Gordana Avlijaš, Krzysztof Grabiński, and Dragana Milinković. Using monte carlo simulation in project management. *Management - Journal of Sustainable Business and Management Solutions in Emerging Economies*, 13(47):33–38, 2008.
- [19] Averill M. Law. *Simulation Modeling and Analysis*. McGraw-Hill Education, 5th edition, 2015.
- [20] Fred Glover. Future paths for integer programming and links to artificial intelligence. *Computers & Operations Research*, 13(5):533–549, 1986.

Popis slika

1	Model problema optimizacije raspodjele projektnih aktivnosti . . .	8
2	Dijagram toka procesa optimizacije korištenjem Monte Carlo simulacije i genetskog algoritma	10
3	Primjer usporedbe prosječne uspješnosti za tri scenarija (primjer, podaci privremeni).	14

Popis tablica